
Instituto Politécnico de Bragança

Centro de Investigação em Digitalização e Robótica Inteligente (CEDRI)

Escola Superior de Tecnologia e Gestão

Relatório de Estágio

Detecção e Classificação Automática de Gomos em Videiras utilizando Visão Computacional e Deep Learning

Robson Alexander Alves

Orientadores: João Mendes
Inês Sena
Maurício Morais

Período: 12 de março de 2026 a 10 de julho de 2026

Instituição: IPB / CEDRI

Bragança, 2026

Agradecimentos

Gostaria de expressar a minha sincera gratidão a todos que tornaram possível a realização deste estágio.

Aos meus orientadores, **João Mendes**, **Inês Sena** e **Maurício Moraes**, pela disponibilidade, pela orientação técnica e científica, e pelo acompanhamento ao longo de todo o período de estágio. O apoio prestado foi fundamental para o desenvolvimento deste trabalho.

Ao **Instituto Politécnico de Bragança (IPB)** e ao **Centro de Investigação em Digitalização e Robótica Inteligente (CEDRI)**, pela infraestrutura disponibilizada e pela oportunidade de desenvolver investigação aplicada numa área de relevância crescente para a agricultura de precisão.

A todos os colegas e investigadores que, direta ou indiretamente, contribuíram com sugestões, discussões e encorajamento ao longo deste percurso.

Resumo

A viticultura é uma das atividades agrícolas com maior relevância económica em Portugal e na Europa. A identificação precisa dos gomos nas videiras é uma etapa fundamental para a estimativa da produção e para a realização da poda mecanizada — tarefa que, se automatizada, pode reduzir significativamente os custos operacionais e a dependência de mão de obra especializada.

O presente relatório descreve o trabalho desenvolvido durante o estágio curricular realizado no **Instituto Politécnico de Bragança (IPB)**, no âmbito do **Centro de Investigação em Digitalização e Robótica Inteligente (CEDRI)**, entre março e julho de 2026. O tema central é a **deteção e classificação automática de gomos em videiras** utilizando técnicas de visão computacional e aprendizagem profunda (*deep learning*).

Durante o estágio foram desenvolvidos três modelos progressivos. O primeiro baseou-se no dataset público **Segmentation-Vineyard-2** [17] (origem espanhola), que continha anotações de *sarmento* e *tronco* — tendo sido adicionadas manualmente as anotações de *gomo* pelo estagiário. Os modelos seguintes incorporaram imagens retiradas de vídeos captados nas vinhas de Palmela, em condições próximas de um sistema robótico real de corte. Estas imagens apresentam elevada complexidade visual, com oclusões, planos de fundo densos (outras videiras, árvores, postes e arames), múltiplos elementos em cena e variações de iluminação. Para lidar com essa complexidade, foram anotadas quatro classes de objetos: *gomos*, *sarmentos*, *troncos* e *objetos* (arames, postes e outros elementos).

O modelo de deteção selecionado foi o **YOLO26 Nano** [3], pela sua eficiência computacional, inferência *NMS-free* e adequação a sistemas embebidos. O processo de anotação e treino foi realizado na plataforma **Roboflow**. O Modelo 2 (400 imagens base, 772 após *data augmentation*) obteve mAP@50 de 48,8%. O Modelo 3 (938 imagens após *augmentation*) obteve mAP@50 de 43,7% e Precisão de 57,3%, com os gomos a surgir nas inferências a limiares de confiança de 16–26%.

Os resultados obtidos evidenciam que a deteção de gomos em cenas reais é um problema exigente, com a complexidade visual a requerer volumes de dados superiores ao que pode ser alcançado num único semestre. As lições aprendidas e os resultados

dos três modelos constituem uma base sólida para trabalhos futuros de maior escala.

Palavras-chave: visão computacional, *deep learning*, YOLO26, detecção de objetos, viticultura, gomos, poda mecanizada, Roboflow.

Abstract

Viticulture is one of the most economically significant agricultural activities in Portugal and across Europe. The accurate identification of buds on grapevines is a critical step for yield estimation and mechanised pruning — a task that, if automated, can substantially reduce operational costs and reliance on skilled labour.

This report describes the work carried out during a curricular internship at the **Polytechnic Institute of Bragança (IPB)**, within the **Research Centre in Digitalization and Intelligent Robotics (CEDRI)**, from March to July 2026. The central theme is the **automatic detection and classification of buds on grapevines** using computer vision and deep learning techniques.

Three progressive models were developed during the internship. The first was based on the publicly available *Segmentation-Vineyard-2* Spanish dataset, to which bud annotations were manually added. Subsequent models incorporated frames extracted from videos captured in the Palmela vineyards, under conditions close to those of a real robotic pruning system. These images exhibit high visual complexity, including occlusions, dense backgrounds (other vines, trees, poles and wires), multiple elements in the scene and lighting variations. Four object classes were annotated: *buds*, *canes* (*sarmentos*), *trunks* and *objects* (wires, poles and other structural elements).

The selected detection model was **YOLO26 Nano** [3], chosen for its computational efficiency, NMS-free inference and suitability for embedded systems. Annotation and training were performed on the **Roboflow** platform. Model 2 (400 base images, expanded to 772 by data augmentation) achieved a mAP@50 of 48.8%. Model 3 (938 images after augmentation) achieved mAP@50 of 43.7% and Precision of 57.3%, with buds appearing in inferences at confidence thresholds of 16–26%.

Results demonstrate that bud detection in real vineyard scenes is a challenging problem. The three models developed establish a solid methodological foundation and provide a realistic assessment of the data volumes required for a production-grade system.

Keywords: computer vision, deep learning, YOLO26, object detection, viticulture, buds, mechanised pruning, Roboflow.

Índice

Agradecimentos	ii
Resumo	iii
Abstract	v
1 Introdução	1
1.1 Contextualização	1
1.2 Motivação	1
1.3 Objetivos	2
1.4 Estrutura do Relatório	3
2 Revisão de Literatura	4
2.1 Visão Computacional e Agricultura de Precisão	4
2.2 Detecção de Objetos com Redes Neurais Profundas	4
2.2.1 Evolução dos Modelos de Detecção	4
2.2.2 A Família YOLO e o YOLO26	5
2.3 Aplicações em Viticultura	5
2.3.1 Detecção de Uvas e Cachos	5
2.3.2 Detecção de Sarmentos e Estrutura da Planta	6
2.3.3 Detecção de Gomos	6
2.4 Plataformas de Anotação de Dados	6
2.5 Desafios em Ambientes Vitícolas Reais	6
3 Metodologia	8
3.1 Visão Geral da Pipeline	8
3.2 Aquisição de Dados	8
3.2.1 Dataset Modelo 1 — Origem Espanhola	8
3.2.2 Dataset Modelo 2 — Vinhas de Palmela	9
3.3 Estratégia de Anotação	9
3.3.1 Classes e Critérios de Anotação	9

3.3.2	Desafios da Anotação nas Imagens de Palmela	10
3.4	Arquitetura do Sistema	13
3.4.1	Modelo: YOLO26 Nano	13
3.4.2	Configuração do Dataset — <code>data.yaml</code>	16
3.4.3	Scripts de Download Automatizado	16
3.5	Procedimento de Treino	16
4	Desenvolvimento	18
	Nota sobre Contagem de Imagens	18
4.1	Modelo 1 — <i>Segmentation-Vineyard-2</i> (fase de validação técnica) . . .	18
4.1.1	Caracterização do Dataset	18
4.1.2	Refinamento das Etiquetas	19
4.1.3	Observações Qualitativas	19
4.2	Modelo 2 — SVY-2 + Palmela (400 imagens base)	19
4.2.1	Justificação e Contexto	19
4.2.2	Processo de Captação de Vídeo	20
4.2.3	Importação e Extração de Frames no Roboflow	20
4.2.4	Evolução da Estratégia de Anotação	20
4.2.5	Dificuldades Específicas e Decisões Tomadas	21
4.2.6	Estado da Anotação e Métricas	21
4.3	Modelo 3 — Dataset Expandido (400+ imagens base, 938 aumentadas) .	22
4.3.1	Contexto e Motivação	22
4.3.2	Composição do Dataset e Resultados	22
4.3.3	Análise dos Resultados do Modelo 3	23
4.4	Considerações sobre a Complexidade do Problema	24
5	Resultados Parciais	25
5.1	Nota Preliminar	25
5.2	Métricas de Avaliação	25
5.3	Resultados do Modelo 1 — <i>Segmentation-Vineyard-2</i>	26
5.4	Resultados do Modelo 2 — SVY-2 + Palmela	26
5.5	Resultados do Modelo 3 — Dataset Expandido	27
5.6	Análise das Dificuldades Observadas	27
5.7	Comparação entre os Três Modelos	28
6	Conclusão e Trabalhos Futuros	29
6.1	Conclusão	29
6.2	Trabalhos Futuros	30
6.2.1	Expansão e Diversificação do Dataset	30

6.2.2	Arquiteturas de Modelo Mais Avançadas	30
6.2.3	Integração com Informação de Profundidade	31
6.2.4	Validação em Ambiente Real	31
6.2.5	Técnicas de <i>Data Augmentation</i> Específicas	31
Referências Bibliográficas		32

Lista de Figuras

3.1	Exemplo de imagem das vinhas de Palmela antes e após anotação manual, ilustrando a elevada densidade de instâncias por frame.	12
3.2	Distribuição do número de instâncias anotadas por classe na imagem de exemplo.	13
3.3	Diagrama de arquitetura do YOLO26 Nano: Backbone (C3k2 + SPPF com atalho residual), Neck (C2PSA com PSABlock de atenção) e três cabeças de detecção (<i>small, medium, large</i>). Fonte: [3].	15
4.1	Inferência do Modelo 3 sobre imagem das vinhas de Palmela (<i>threshold</i> = 16%). Sarmentos (ciano), gomos (roxo), objetos (vermelho). Os sarmentos atingem confiança até 91%; os gomos surgem apenas com confiança de 16–26%, indicando que a classe está a ser aprendida mas requer mais dados.	23
5.1	Inferência do Modelo 3 (<i>threshold</i> = 16%). Os sarmentos (ciano) são detetados com confiança até 91%; os gomos (roxo) surgem com confiança de 16–26%; um obstáculo/poste é detetado a vermelho com 71%.	27

Lista de Tabelas

3.1	Estatísticas do Dataset de Palmela (estado atual)	9
3.2	Classes de anotação, propósito robótico e critérios de anotação	10
3.3	Configuração de treino no Roboflow Train	17
4.1	Composição dos datasets por modelo (imagens base vs. após <i>data augmentation</i>)	18
4.2	Métricas do Modelo 2 no conjunto de validação (Roboflow Train) . . .	21
4.3	Métricas do Modelo 3 no conjunto de validação (Roboflow Train) . . .	22
5.1	Resultados do Modelo 2 (validação) — SVY-2 + Palmela, 772 imagens	26
5.2	Resultados do Modelo 3 (validação) — 938 imagens	27
5.3	Comparação entre os três modelos desenvolvidos	28

Capítulo 1

Introdução

1.1 Contextualização

A agricultura de precisão tem beneficiado de forma crescente dos avanços em inteligência artificial, robótica e visão computacional. No contexto da viticultura, a automatização de processos como a poda e a estimativa de produção representa um desafio técnico relevante, com impacto direto na competitividade do setor e na redução de custos operacionais.

A poda da videira é uma das operações culturais mais exigentes em termos de mão de obra. Realizada tipicamente durante o inverno e início da primavera, requer o reconhecimento dos sarmentos produtivos — denominados **sarmentos** — e a identificação dos gomos que se pretendem preservar para garantir a produção da safra seguinte. A realização desta tarefa de forma manual depende de operários experientes, sendo sujeita a variações decorrentes de fatores humanos. A sua mecanização exige, portanto, que sistemas robóticos sejam capazes de perceber e interpretar a estrutura visual complexa de uma videira.

É neste enquadramento que surge o presente estágio, desenvolvido no **Instituto Politécnico de Bragança (IPB)**, no **Centro de Investigação em Digitalização e Robótica Inteligente (CEDRI)**, com o objetivo de investigar e implementar uma solução baseada em *deep learning* para a **deteção automática de gomos em videiras**.

1.2 Motivação

A identificação automática e precisa de gomos numa videira constitui um pré-requisito para qualquer sistema de poda autónoma. Sem esta capacidade, um robô de poda não consegue determinar a posição de corte adequada acima de um gomo, o que comprometeria a integridade da planta e a produção futura.

A motivação deste trabalho assenta em três eixos principais:

1. **Relevância económica:** Portugal é um dos maiores produtores de vinho do mundo, sendo a viticultura um pilar da economia agrícola nacional. A automação de operações de poda pode traduzir-se em poupanças significativas.
2. **Desafio técnico:** As videiras constituem cenários de elevada complexidade visual, com sobreposição de elementos, variações de iluminação e grande diversidade morfológica entre cultivares e condições de crescimento.
3. **Alinhamento com investigação atual:** A área de deteção de objetos em contextos agrícolas tem vindo a crescer rapidamente, com modelos baseados em redes neuronais convolucionais e *transformers* a alcançar resultados encorajadores em tarefas relacionadas.

1.3 Objetivos

O presente estágio tem como objetivos gerais:

- Recolher, processar e anotar imagens de videiras em condições próximas de um cenário robótico real;
- Treinar e avaliar modelos de deteção de objetos baseados em *deep learning* para a identificação de gomos, sarmentos, troncos e outros elementos estruturais da videira;
- Estabelecer uma metodologia replicável de construção de dataset e de treino de modelos, adaptada às condicionantes do ambiente vitícola;
- Identificar os principais desafios e limitações do problema, e propor direções para trabalho futuro.

No que respeita os objetivos específicos, pretende-se:

- Desenvolver e validar um modelo YOLO26 treinado sobre imagens provenientes de vinhas da região de Palmela;
- Avaliar a viabilidade do uso de *transfer learning* a partir de um dataset externo (espanhol) para acelerar a convergência do modelo;
- Quantificar o esforço de anotação necessário para um desempenho aceitável em cenas complexas;
- Documentar a pipeline completa, desde a captura de vídeo até à inferência do modelo.

1.4 Estrutura do Relatório

Este relatório encontra-se organizado da seguinte forma:

Capítulo 2 apresenta a revisão da literatura, cobrindo os conceitos fundamentais de visão computacional, detecção de objetos e aplicações em viticultura.

Capítulo 3 descreve a metodologia adotada, incluindo a estratégia de captura de imagens, as ferramentas utilizadas e a arquitetura do sistema.

Capítulo 4 detalha o processo de desenvolvimento, com especial ênfase na anotação de dados, na configuração dos modelos e nos desafios encontrados.

Capítulo 5 apresenta os resultados parciais obtidos, com análise das métricas de desempenho e exemplos visuais de detecção.

Capítulo 6 sintetiza as conclusões, discute as limitações do trabalho e aponta perspectivas para investigação futura.

Capítulo 2

Revisão de Literatura

2.1 Visão Computacional e Agricultura de Precisão

A visão computacional é um ramo da inteligência artificial que visa dotar sistemas computacionais da capacidade de interpretar e compreender informação visual proveniente do mundo real. Nas últimas décadas, os avanços em redes neuronais profundas (*deep neural networks*) transformaram profundamente o estado da arte nesta área, permitindo alcançar níveis de desempenho comparáveis ou superiores ao humano em diversas tarefas de reconhecimento e detecção de objetos [6].

No contexto da **agricultura de precisão**, a visão computacional tem sido aplicada a um conjunto diversificado de problemas: detecção de pragas e doenças em folhas [9], estimativa do estado de maturação de frutos [15], mapeamento de culturas por drones e contagem de plantas [11]. A viticultura, em particular, tem atraído crescente atenção da comunidade científica, dado o valor económico da cultura e a complexidade visual do ambiente de vinha.

2.2 Detecção de Objetos com Redes Neuronais Profundas

2.2.1 Evolução dos Modelos de Detecção

Os modelos modernos de detecção de objetos podem ser classificados em duas grandes famílias:

- **Modelos em dois estágios** (*two-stage detectors*): Como o Faster R-CNN [13], que primeiro gera propostas de regiões e depois as classifica. Tendem a apresentar maior precisão, mas com latência mais elevada.

- **Modelos em um estágio** (*single-stage detectors*): Como a família YOLO (*You Only Look Once*) [12] e o SSD [7], que realizam a detecção numa única passagem pela rede. São mais rápidos e adequados a aplicações em tempo real.

Para sistemas embebidos e robóticos, os modelos de um estágio são preferíveis devido ao menor custo computacional.

2.2.2 A Família YOLO e o YOLO26

A arquitetura YOLO foi introduzida por Redmon *et al.* [12] e tem sido continuamente aprimorada. O **YOLOv8**, desenvolvido pela Ultralytics [4], representou um marco importante, com melhorias na arquitetura do *backbone*, do *neck* e da cabeça de detecção (*detection head*).

O **YOLO26** [3], versão mais recente da família, introduz avanços significativos sobre o YOLOv8:

- Eliminação da *Distribution Focal Loss* (DFL) e adoção de inferência *End-to-End NMS-Free*, reduzindo a latência em 43% no modo CPU;
- Introdução do **STAL** (*Small-Target-Aware Label Assignment*), que corrige a sub-atribuição de objetos com dimensão inferior a 8×8 px — especialmente relevante para a detecção de gomos;
- Bloco de atenção **PSABlock** no *neck*, melhorando a representação de características sem custo computacional elevado;
- Otimizador **MuSGD**, que combina SGD com atualizações estilo Muon, melhorando a convergência.

A variante **YOLO26 Nano** é a mais leve da família, adequada para execução em tempo real em hardware com recursos limitados, como sistemas robóticos de campo. O modelo retorna, para cada objeto detectado, uma *bounding box*, uma classe e um valor de confiança.

2.3 Aplicações em Viticultura

2.3.1 Detecção de Uvas e Cachos

Vários trabalhos têm abordado a detecção de uvas e cachos em imagens de campo. Santos *et al.* [16] e Nuske *et al.* [10] utilizaram visão computacional para estimar o rendimento das vinhas através da contagem de cachos. A complexidade das oclusões e a variabilidade de cor entre cultivares são apontadas como os principais desafios.

2.3.2 Detecção de Sarmentos e Estrutura da Planta

A identificação da estrutura esquelética da videira — tronco, cordões e sarmentos — é uma etapa anterior à localização dos gomos e tem sido explorada por Kicherer *et al.* [5] e Majeed *et al.* [8]. Estes trabalhos demonstram que a segmentação ou deteção dos elementos estruturais melhora a robustez da localização dos pontos de corte.

2.3.3 Detecção de Gomos

A deteção específica de gomos (*buds*) é uma tarefa de menor dimensão aparente, mas de alta dificuldade, dado que os gomos têm dimensão reduzida e podem apresentar-se parcialmente oclusos por folhas ou outros sarmentos. Botterill *et al.* [2] desenvolveram um sistema robótico de poda que inclui deteção de gomos com câmeras RGB e de profundidade. Aquino *et al.* [1] focaram-se em cultivares espanholas e obtiveram resultados promissores com redes convolucionais.

2.4 Plataformas de Anotação de Dados

A qualidade e consistência das anotações são determinantes para o desempenho de modelos supervisionados. A plataforma **Roboflow** [14] tem emergido como uma das ferramentas mais completas para:

- Anotação manual de *bounding boxes* e polígonos;
- Aplicação de técnicas de *data augmentation* (rotação, flip, ajuste de brilho, corte, mosaico);
- Exportação de datasets nos formatos suportados pelos principais frameworks (YOLO, COCO, Pascal VOC);
- Gestão de versões de dataset e colaboração em equipa.

A existência de datasets públicos na plataforma, incluindo conjuntos provenientes de Espanha e de outros países produtores de vinho, facilita a aplicação de *transfer learning* e a expansão de dados de treino.

2.5 Desafios em Ambientes Vitícolas Reais

A literatura aponta de forma recorrente um conjunto de desafios específicos ao ambiente de vinha que dificultam a deteção robusta de objetos:

Oclusão e sobreposição: Os sarmentos de diferentes plantas cruzam-se frequentemente, e os gomos podem ficar parcialmente ocultos por outros elementos da planta ou por vegetação de fundo.

Variações de iluminação: A luz solar direta, a sombra projetada pelos sarmentos e as mudanças ao longo do dia afetam significativamente a aparência visual dos gomos e sarmentos.

Fundo complexo: Em vinhas alinhadas, o fundo de uma imagem de um sarmento em primeiro plano inclui tipicamente outros sarmentos, folhas e estruturas de suporte, tornando difícil a distinção entre objetos de interesse e contexto.

Variabilidade morfológica: As dimensões, formas e aspetos dos gomos variam consideravelmente entre cultivares, fases de crescimento e condições de stresse hídrico.

Estes desafios motivam a necessidade de recolher imagens em condições reais e de construir datasets com grande diversidade, como descrito no presente trabalho.

Capítulo 3

Metodologia

3.1 Visão Geral da Pipeline

O sistema desenvolvido neste estágio segue uma *pipeline* típica de um projeto de visão computacional supervisionada, organizada nas seguintes etapas:

1. **Aquisição de dados:** captura de vídeo em campo e extração de frames;
2. **Seleção e anotação:** filtragem das imagens representativas e marcação manual das classes de interesse na plataforma Roboflow;
3. **Organização do dataset:** divisão em conjuntos de treino, validação e teste, com exportação no formato YOLO;
4. **Treino do modelo:** configuração e treino do YOLO26 Nano com os dados anotados;
5. **Avaliação:** análise das métricas de desempenho sobre o conjunto de teste;
6. **Inferência:** aplicação do modelo treinado a novos frames de vídeo.

3.2 Aquisição de Dados

3.2.1 Dataset Modelo 1 — Origem Espanhola

O primeiro modelo foi treinado com recurso ao dataset público **Segmentation-Vineyard-2** [17], disponível na plataforma Roboflow Universe e oriundo de investigações em vinhas espanholas pelo grupo Vinya. O dataset original continha exclusivamente anotações de **sarmento** e **tronco**, sem qualquer marcação de gomos.

A principal contribuição deste estágio ao Modelo 1 foi a **anotação manual dos gomos** em todas as imagens do dataset — tarefa realizada na plataforma Roboflow — completando assim as três classes de interesse: **gomo**, **sarmento** e **tronco**.

3.2.2 Dataset Modelo 2 — Vinhas de Palmela

O segundo modelo, de maior complexidade e relevância aplicacional, foi construído a partir de vídeos captados presencialmente nas vinhas da região de **Palmela**, em Portugal. A captação foi realizada com uma câmera de smartphone, a uma taxa de **2 frames por segundo**, posicionada de forma a simular o ponto de vista de um robô de poda que se desloca ao longo das filas de videiras.

Os vídeos foram importados diretamente para o Roboflow, que permite a extração automática de frames e a sua apresentação sequencial para anotação. Foram captados múltiplos ângulos e condições de iluminação, de modo a maximizar a diversidade do dataset.

A Tabela 3.1 resume as características do dataset de Palmela no estado atual.

Tabela 3.1: Estatísticas do Dataset de Palmela (estado atual)

Parâmetro	Valor
Imagens anotadas	≈ 100 (Palmela) + 300 (espanhol)
Taxa de captura	2 frames/segundo
Classes anotadas	4 (gomo, sarmento, tronco, objeto)
Ferramenta de anotação	Roboflow
Formato de exportação	YOLO (TXT + <code>data.yaml</code>)
Divisão treino/val/teste	70% / 20% / 10%

3.3 Estratégia de Anotação

A anotação foi realizada manualmente na interface de rotulagem do Roboflow. Para cada imagem, foram desenhadas *bounding boxes* em torno de cada instância das quatro classes definidas.

3.3.1 Classes e Critérios de Anotação

A definição das classes resultou de uma análise iterativa das necessidades do sistema robótico e das dificuldades encontradas nas primeiras sessões de anotação. Cada classe serve um propósito específico na operação do robô:

Tabela 3.2: Classes de anotação, propósito robótico e critérios de anotação

Classe	Propósito robótico	Critério de anotação
gomo	Alvo principal: determina os pontos de corte para a poda	<i>Bounding box</i> ajustada ao contorno do gomo. Anotados todos os gomos identificáveis, dado que a sua posição ao longo dos sarmentos é reconhecível mesmo a distância.
sarmento	Guia estrutural: os gomos crescem ao longo dos sarmentos, pelo que a sua deteção facilita a localização dos gomos	Caixa delimitadora ao longo do sarmento visível; sarmentos parcialmente oclusos são anotados se pelo menos 30% estiver visível.
tronco	Navegação: permite ao robô identificar cada videira e orientar o percurso ao longo da fila	Incluído para guia de navegação e para evitar confusão com sarmentos de fundo.
objeto	Segurança: identifica estacas, mangueiras e outros obstáculos que o robô deve evitar durante o deslocamento	Anotados os elementos não classificáveis nas outras classes que possam representar obstáculos físicos.

3.3.2 Desafios da Anotação nas Imagens de Palmela

As imagens retiradas dos vídeos de Palmela apresentam um grau de complexidade visual significativamente superior ao do dataset espanhol. Entre os principais desafios encontrados durante a anotação destacam-se:

- **Planos de fundo densos:** As imagens captadas numa vinha com formação em espaldeira apresentam, ao fundo, outras fileiras de videiras, arames de suporte, árvores e, nalguns casos, estruturas agrícolas. Esta sobreposição de elementos dificulta a distinção entre o sarmento em primeiro plano e os elementos de contexto.
- **Oclusão múltipla:** É frequente que gomos de um sarmento estejam parcialmente cobertos por outros sarmentos, folhas remanescentes ou pela própria curvatura do ramo. Nas imagens de inverno/início de primavera, sem folhagem, a estrutura é mais visível, mas o número de sarmentos em cena é muito elevado.

- **Variações de iluminação:** A luz solar direta cria reflexos brilhantes nos sarmentos, enquanto zonas de sombra resultam em perda de detalhe. O uso de múltiplos ângulos de captação agrava esta variabilidade.
- **Densidade de instâncias:** Numa única imagem pode existir um elevado número de gomos (dezenas), o que torna a anotação exaustiva e propícia a omissões.
- **Lentidão da ferramenta com muitas anotações:** A experiência prática revelou que, quando uma imagem acumula mais de 300 *bounding boxes* anotadas, a interface do Roboflow torna-se significativamente mais lenta, dificultando a navegação e o desenho de novas caixas. Este problema limita a eficiência das sessões de anotação em frames de alta densidade.
- **Ausência de seleção automática para sarmentos:** O Roboflow disponibiliza uma funcionalidade de seleção automática de objetos (Smart Polygon / Auto-label) baseada em inteligência artificial. Contudo, esta ferramenta mostrou-se pouco eficaz na deteção de **sarmentos** — estruturas finas, alongadas e frequentemente sobrepostas. Na grande maioria dos casos, os sarmentos tiveram de ser anotados inteiramente à mão, através do desenho manual da *bounding box*, o que aumentou consideravelmente o tempo total de anotação.
- **Semelhança visual inter-classe:** Sarmentos finos, fios metálicos e troncos jovens apresentam aspeto visual similar, exigindo atenção redobrada por parte do anotador.

A Figura 3.1 ilustra um exemplo representativo das complexidades presentes nas imagens de Palmela.



(a) Imagem original (sem anotações)


(b) Mesma imagem com anotações (>300 *bounding boxes*)

Figura 3.1: Exemplo de imagem das vinhas de Palmela antes e após anotação manual, ilustrando a elevada densidade de instâncias por frame.




Figura 3.2: Distribuição do número de instâncias anotadas por classe na imagem de exemplo.

3.4 Arquitetura do Sistema

3.4.1 Modelo: YOLO26 Nano

O modelo de detecção selecionado foi o **YOLO26 Nano**, a versão mais recente da família YOLO (*You Only Look Once*), desenvolvida pela Ultralytics e documentada por Hidayatullah e Tubagus [3]. Lançado em janeiro de 2026 com o lema "*Built End-to-End. Built for the Edge*", o YOLO26 foi concebido para maximizar a eficiência em dispositivos de baixo custo computacional, mantendo elevada precisão. A escolha recaiu sobre a variante **Nano** (a mais leve da família) pelos seguintes motivos:

- **Inferência sem NMS (*Non-Maximum Suppression*):** Versões anteriores do YOLO necessitavam de uma etapa de pós-processamento chamada NMS, que filtrava detecções sobrepostas calculando a interseção sobre a união (*IoU*) entre caixas. O YOLO26 elimina esta etapa através de inferência *End-to-End NMS-Free*: durante o treino são utilizadas duas cabeças de detecção simultâneas (*one-to-many*

e *one-to-one*); na inferência apenas a cabeça *one-to-one* é usada, produzindo diretamente um conjunto limitado de detecções de alta confiança sem necessidade de filtragem posterior. O resultado é uma redução de 43% na latência no modo CPU face ao YOLOv8.

- **Eliminação da DFL (*Distribution Focal Loss*):** Versões anteriores estimavam as caixas delimitadoras como distribuições de probabilidade (DFL), adicionando complexidade computacional e dependência do NMS. O YOLO26 substitui esta abordagem por regressão direta de coordenadas, simplificando o *pipeline* de treino e inferência.
- **SPPF com atalho residual (*Spatial Pyramid Pooling Fast*):** O bloco SPPF, que agrega características a múltiplas escalas, passa a incluir uma ligação residual (*shortcut*), melhorando o fluxo de gradiente e a estabilidade do treino.
- **PSABlock (*Polarized Self-Attention Block*):** O último bloco C3k2 do *neck* incorpora um mecanismo de atenção global (PSABlock), melhorando a modelação de contexto sem aumento significativo de parâmetros ou latência.
- **STAL (*Small-Target-Aware Label Assignment*):** Melhoria sobre o método de atribuição de etiquetas TAL (*Task Alignment Learning*), que ignorava objetos muito pequenos. O STAL garante um mínimo de quatro âncoras para objetos com dimensão inferior a 8×8 px (numa imagem de 640×640 px) — relevante para a detecção de gomos de pequena dimensão nas imagens de campo.
- **ProgLoss (*Progressive Loss Balancing*):** Ajusta dinamicamente o peso de cada cabeça de detecção ao longo do treino: nas primeiras épocas, a cabeça *one-to-many* recebe maior peso para estabilizar a aprendizagem; progressivamente, o peso transfere-se para a cabeça *one-to-one*, alinhando o treino com o comportamento de inferência.
- **MuSGD (*Muon Stochastic Gradient Descent*):** Otimizador híbrido que combina o SGD (*Stochastic Gradient Descent*) clássico com atualizações estilo Muon (originalmente desenvolvido para treino de LLMs — *Large Language Models*). O resultado é uma convergência mais rápida e estável, especialmente em datasets de dimensão reduzida.
- **Suporte a *transfer learning*:** Os pesos pré-treinados no dataset COCO permitem uma inicialização favorável, acelerando a convergência mesmo com datasets de pequena dimensão.

A Figura 3.3 apresenta o diagrama detalhado da arquitetura do YOLO26, o primeiro diagrama publicado para este modelo [3]. A arquitetura organiza-se em três regiões: **Backbone** (blocos C3k2 com convoluções de *stride* 2 para extração de características a quatro escalas), **Neck** (SPPF com atalho residual + C2PSA com PSABlock de atenção global + blocos de *upsample* e concatenação) e **Head** (três cabeças de detecção para objetos pequenos, médios e grandes).




Figura 3.3: Diagrama de arquitetura do YOLO26 Nano: Backbone (C3k2 + SPPF com atalho residual), Neck (C2PSA com PSABlock de atenção) e três cabeças de detecção (*small*, *medium*, *large*). Fonte: [3].

3.4.2 Configuração do Dataset — data.yaml

A organização do dataset segue a estrutura padrão do YOLO, com as pastas `train/`, `valid/` e `test/`, cada uma contendo as sub-pastas `images/` e `labels/`. O ficheiro `data.yaml` descreve o dataset ao modelo:

```
1 path: /datasets/palmela_v1
2 train: train/images
3 val:   valid/images
4 test:  test/images
5
6 nc: 4
7 names:
8   0: gomo
9   1: sarmento
10  2: tronco
11  3: objeto
```

Listing 3.1: Exemplo de `data.yaml` para o dataset de Palmela

3.4.3 Scripts de Download Automatizado

Para automatizar o download de datasets do Roboflow, foi desenvolvido um script Python que utiliza a API da plataforma:

```
1 from roboflow import Roboflow
2
3 rf = Roboflow(api_key="SUA_API_KEY")
4 project = rf.workspace("nome-workspace").project("nome-projeto")
5 dataset = project.version(1).download("yolov8")
```

Listing 3.2: Download automático de dataset via API Roboflow

3.5 Procedimento de Treino

O treino dos modelos foi realizado diretamente na plataforma **Roboflow**, recorrendo à funcionalidade de treino na nuvem (*Roboflow Train*). Esta abordagem dispensa a configuração de um ambiente local com GPU, uma vez que a plataforma disponibiliza infraestrutura de computação gerida.

O processo de treino na plataforma segue os seguintes passos:

1. Selecionar a versão do dataset a treinar no projeto Roboflow;
2. Escolher o modelo base — foi utilizado o **YOLO26 Nano** com pesos pré-treinados no COCO;
3. Definir o número de épocas e iniciar o treino;
4. Acompanhar as métricas de desempenho (mAP, Precisão, Recall) em tempo real no painel da plataforma;
5. Descarregar os pesos do modelo treinado (**best.pt**) após conclusão.

Tabela 3.3: Configuração de treino no Roboflow Train

Parâmetro	Valor
Plataforma de treino	Roboflow Train (nuvem)
Modelo base	YOLO26 Nano (COCO)
Épocas (epochs)	100
Tamanho de imagem	640
Divisão treino/val/teste	70% / 20% / 10%
Pesos exportados	best.pt (formato PyTorch)

Capítulo 4

Desenvolvimento

Nota sobre Contagem de Imagens

Durante o treino na plataforma Roboflow Train, a plataforma aplica automaticamente técnicas de *data augmentation* (rotações, espelhos, variações de brilho e contraste, entre outras) sobre as imagens anotadas. Os valores de contagem de imagens reportados no painel do Roboflow referem-se sempre ao total **após augmentation**, e não ao número de imagens base originalmente anotadas.

A Tabela 4.1 resume a composição de cada versão do dataset, distinguindo as contagens base das contagens pós-augmentation.

Tabela 4.1: Composição dos datasets por modelo (imagens base vs. após *data augmentation*)

Modelo	Base SVY-2	Base Palmela	Base total	Após augmentation (Roboflow)
Modelo 1	300	0	300	≈775
Modelo 2	300	100	400	772
Modelo 3	300	100+	400+	938

4.1 Modelo 1 — *Segmentation-Vineyard-2* (fase de validação técnica)

4.1.1 Caracterização do Dataset

O primeiro modelo foi desenvolvido com base no dataset público **Segmentation-Vineyard-2** [17], disponível na plataforma Roboflow Universe e de origem espanhola.

Este dataset continha originalmente apenas anotações de **sarmento** e **tronco** — não incluía qualquer anotação de gomos.

A contribuição deste estágio consistiu em anotar manualmente os gomos em cada uma das 300 imagens do dataset, acrescentando a classe **gomo** ao conjunto de etiquetas existente. O Modelo 1 passou assim a ter três classes: **gomo**, **sarmento** e **tronco**. O dataset foi dividido na plataforma Roboflow nas proporções 70% treino / 20% validação / 10% teste. Após a aplicação de *data augmentation* pelo Roboflow, o conjunto de treino atingiu aproximadamente 775 imagens.

O processo de desenvolvimento do Modelo 1 serviu como etapa de validação da *pipeline* técnica e permitiu confirmar a viabilidade do fluxo completo de anotação, treino e inferência antes de introduzir as imagens de Palmela, de maior complexidade.

4.1.2 Refinamento das Etiquetas

Após uma inspeção visual inicial do **Segmentation-Vineyard-2**, foram identificadas algumas inconsistências nas anotações de **sarmento** e **tronco** — *bounding boxes* excessivamente largas ou com sobreposição não intencional. Procedeu-se ao refinamento manual de parte dessas anotações, em simultâneo com a adição das anotações de **gomo**.

4.1.3 Observações Qualitativas

A inferência sobre imagens do conjunto de teste revelou que o modelo identifica corretamente os sarmentos com elevada confiança (até 97%) e os troncos com boa confiança (acima de 83%). As métricas formais deste modelo foram obtidas apenas na versão do Roboflow correspondente ao Modelo 2 (que utilizou o mesmo dataset base acrescido das imagens de Palmela), dado que ambas as versões foram treinadas numa única sessão sequencial na plataforma.

4.2 Modelo 2 — SVY-2 + Palmela (400 imagens base)

4.2.1 Justificação e Contexto

O desenvolvimento do segundo modelo representa o núcleo do trabalho prático deste estágio. A motivação para a criação de um novo dataset, em vez de reutilizar integralmente o dataset espanhol, reside na diferença substancial entre as condições das imagens disponíveis publicamente e as condições reais de operação de um robô de poda nas vinhas portuguesas.

As imagens do **Segmentation-Vineyard-2** foram, na sua maioria, captadas em condições controladas ou com planos de fundo limpos. Em contrapartida, um robô real que percorra as vinhas de Palmela capturará cenas com:

- Múltiplas videiras visíveis em simultâneo (primeiro e segundo planos);
- Arames de suporte, postes e outros elementos de infraestrutura;
- Reflexos de luz solar e variações abruptas de contraste;
- Sarmentos de diferentes espessuras e comprimentos que se cruzam e sobrepõem no campo visual.

É precisamente esta realidade que o Modelo 2 pretende capturar.

4.2.2 Processo de Captação de Vídeo

Os vídeos utilizados para construir o dataset de Palmela foram captados durante uma visita às vinhas da região, realizada em março de 2026. A captação foi efetuada com câmara de smartphone em modo vídeo, percorrendo as fileiras de videiras a pé, de forma a simular o deslocamento de um robô agrícola.

Para cobrir diferentes perspetivas e condições de iluminação, foram realizadas passagens ao longo de várias filas em diferentes horas do dia. A taxa de captura foi configurada em **2 frames por segundo** no Roboflow, o que corresponde a uma amostragem suficiente para capturar a diversidade visual sem criar um número excessivo de frames redundantes.

4.2.3 Importação e Extração de Frames no Roboflow

Os ficheiros de vídeo (formato **.mp4**) foram importados diretamente para o projeto no Roboflow. A plataforma realiza automaticamente a extração dos frames à taxa configurada e apresenta-os sequencialmente para anotação. Esta funcionalidade reduziu significativamente o tempo de pré-processamento manual dos dados.

4.2.4 Evolução da Estratégia de Anotação

Ao longo das sessões de anotação do dataset de Palmela, a estratégia foi sendo refinada com base nas dificuldades encontradas. A decisão de incluir as classes **tronco** e **objeto** surgiu após as primeiras experiências de treino revelarem que o modelo confundia estes elementos com sarmentos e gomos.

A inclusão dos sarmentos como classe própria — e não apenas como contexto — foi igualmente determinante. Ao delimitar os sarmentos, o modelo adquire um guia

estrutural que facilita a localização dos gomos, que crescem ao longo dos sarmentos em posições relativamente regulares.

4.2.5 Dificuldades Específicas e Decisões Tomadas

Densidade de instâncias por imagem. Cada imagem das vinhas de Palmela pode conter dezenas de gomos visíveis. A política de anotação adoptada foi a de marcar o máximo de gomos identificáveis em cada imagem. Esta decisão baseia-se numa característica biológica favorável: os gomos crescem em posições regulares e previsíveis ao longo dos sarmentos, pelo que os seus locais de inserção são reconhecíveis mesmo a distância ou em condições de visibilidade parcial. Omitir gomos identificáveis introduziria falsos negativos sistemáticos no treino, prejudicando a capacidade de *recall* do modelo.

Ambiguidade de fronteiras entre classes. Em certas imagens, a distinção entre um sarmento em primeiro plano e um tronco em segundo plano é subjetiva. Foi adotada a regra de que a classe é determinada pela posição relativa ao plano focal principal: o elemento mais próximo da câmara é classificado pelo seu tipo real.

Gomos muito pequenos. Em imagens captadas a maior distância, os gomos aparecem com dimensões inferiores a 15×15 px. Estes casos foram anotados quando identificáveis, mas reconhece-se que o modelo terá maior dificuldade em detetá-los.

4.2.6 Estado da Anotação e Métricas

Até à data de elaboração deste relatório, foram anotadas aproximadamente 100 imagens provenientes das vinhas de Palmela, que foram combinadas com as 300 imagens do Segmentation-Vineyard-2 para compor o dataset do Modelo 2 (400 imagens base no total). Após a aplicação de *data augmentation* pelo Roboflow, o conjunto de treino atingiu 772 imagens, divididas nas proporções 70% treino / 20% validação / 10% teste.

A Tabela 4.2 apresenta as métricas obtidas no conjunto de validação.

Tabela 4.2: Métricas do Modelo 2 no conjunto de validação (Roboflow Train)

Métrica	Valor
mAP@50	48,8%
Precisão	54,3%
Recall	52,7%
F1-Score	53,5%

Os resultados são moderados mas coerentes com a natureza do Modelo 2: dataset de domínio misto (espanhol + português), quatro classes com densidades de instâncias muito distintas, e uma classe (`gomo`) completamente nova relativamente ao dataset base. A precisão de 54,3% e o recall de 52,7% equilibrados indicam que o modelo distribui as dificuldades de forma homogénea, sem enviesamento sistemático.

O dataset encontra-se versionado no Roboflow, permitindo reprodutibilidade dos treinos e rastreabilidade das alterações de anotação.

4.3 Modelo 3 — Dataset Expandido (400+ imagens base, 938 aumentadas)

4.3.1 Contexto e Motivação

Com base nos resultados do Modelo 2 e na análise qualitativa das inferências, foi construída uma terceira versão do dataset com imagens de Palmela adicionais. O objetivo foi avaliar se o aumento do volume de dados resultaria numa melhoria das métricas, em particular no Recall da classe `gomo`.

4.3.2 Composição do Dataset e Resultados

O dataset do Modelo 3 foi gerado em 17 de junho de 2026, com um total de 938 imagens após augmentation. A Tabela 4.3 resume as métricas obtidas no conjunto de validação.

Tabela 4.3: Métricas do Modelo 3 no conjunto de validação (Roboflow Train)

Métrica	Valor
mAP@50	43,7%
Precisão	57,3%
Recall	40,5%
F1-Score	47,4%

A Figura 4.1 mostra uma inferência do Modelo 3 sobre uma imagem das vinhas de Palmela, com *confidence threshold* de 16%.




Figura 4.1: Inferência do Modelo 3 sobre imagem das vinhas de Palmela ($threshold = 16\%$). Sarmentos (ciano), gomos (roxo), objetos (vermelho). Os sarmentos atingem confiança até 91%; os gomos surgem apenas com confiança de 16–26%, indicando que a classe está a ser aprendida mas requer mais dados.

4.3.3 Análise dos Resultados do Modelo 3

A comparação entre o Modelo 2 ($mAP@50 = 48,8\%$) e o Modelo 3 ($mAP@50 = 43,7\%$) revela uma descida ligeira nas métricas globais, que se explica pelo aumento da complexidade do dataset — mais imagens de Palmela com maior densidade de instâncias e mais variação visual. Não obstante, a Precisão subiu de 54,3% para 57,3%, o que indica menos falsos positivos. O Recall de 40,5% reflete a dificuldade em detetar gomos com confiança suficiente para ultrapassar o limiar de 50%.

A análise da inferência (Figura 4.1) revela que:

- Os sarmentos são detetados com elevada confiança (até 91%);
- Um objeto (estaca/poste) é detetado corretamente com 71% de confiança;
- Os gomos surgem com confiança de 16–26%, indicando que o modelo está a aprender a classe, mas o volume de dados ainda é insuficiente para calibrar a confiança neste nível.

Este comportamento é esperado para uma classe de pequena dimensão com elevada variabilidade intra-classe e volume de dados limitado.

4.4 Considerações sobre a Complexidade do Problema

A experiência acumulada durante o estágio permite afirmar que a tarefa de detecção de gomos em cenas reais de vinha, com a complexidade visual observada nas imagens de Palmela, é um problema que excede o que pode ser resolvido satisfatoriamente num único semestre de trabalho. As razões são múltiplas:

1. Volume de dados: modelos de detecção de objetos em cenas complexas tipicamente requerem milhares de imagens anotadas por classe. Com 100 imagens de Palmela (400+ no total com as espanholas), o modelo está limitado na sua capacidade de generalização.
2. Complexidade de anotação: a anotação de imagens com grande densidade de instâncias é demorada e exige consistência. A taxa de anotação estimada é de 15–25 imagens por hora para imagens de alta densidade.
3. Variabilidade do domínio: as condições de iluminação, fenologia e morfologia variam significativamente entre épocas do ano, o que implica a necessidade de múltiplas rondas de captura.
4. Otimização do modelo: a escolha dos hiperparâmetros e das técnicas de *data augmentation* adequadas ao domínio específico requer múltiplas iterações de treino e avaliação.

Não obstante, o trabalho desenvolvido até ao momento estabelece uma base metodológica sólida e fornece uma avaliação realista dos desafios envolvidos, constituindo um ponto de partida valioso para projetos de continuação.

Capítulo 5

Resultados Parciais

5.1 Nota Preliminar

O presente capítulo reporta os resultados obtidos até à data de elaboração deste relatório. Foram treinados três modelos progressivos sobre datasets de complexidade crescente, todos utilizando a plataforma Roboflow Train com o modelo base YOLO26 Nano. As contagens de imagens indicadas referem-se sempre ao total após a aplicação de *data augmentation* pelo Roboflow.

5.2 Métricas de Avaliação

Para avaliar o desempenho dos modelos, são utilizadas as seguintes métricas padrão na literatura de detecção de objetos:

Precisão (P): Fração das detecções positivas que são corretas.

$$P = \frac{TP}{TP + FP}$$

Recall (R): Fração dos objetos reais que foram detetados.

$$R = \frac{TP}{TP + FN}$$

F1-Score: Média harmónica entre Precisão e Recall.

$$F1 = 2 \cdot \frac{P \cdot R}{P + R}$$

mAP@50: *Mean Average Precision* com limiar de IoU de 0,50. Métrica principal utilizada para comparação de modelos na literatura.

mAP@50-95: Média do mAP calculado para limiares de IoU de 0,50 a 0,95 (em passos de 0,05). Métrica mais exigente, adotada no COCO *benchmark*.

onde TP = Verdadeiros Positivos, FP = Falsos Positivos, FN = Falsos Negativos.

5.3 Resultados do Modelo 1 — *Segmentation-Vineyard-2*

O Modelo 1 foi treinado exclusivamente sobre as 300 imagens do *Segmentation-Vineyard-2* com as anotações de *gomo* adicionadas, resultando em aproximadamente 775 imagens após augmentation. Este modelo serviu principalmente para validar a *pipeline* técnica. A inferência visual sobre imagens do conjunto de teste revelou que o modelo identifica corretamente os sarmentos com elevada confiança (até 97%) e os troncos com boa confiança (acima de 83%), validando a capacidade do YOLO26 Nano de aprender a estrutura visual das videiras mesmo com datasets de dimensão reduzida.

5.4 Resultados do Modelo 2 — SVY-2 + Palmela

A Tabela 5.1 apresenta as métricas obtidas pelo Modelo 2 no conjunto de validação, após treino sobre 772 imagens (augmentation de 400 imagens base: 300 do *Segmentation-Vineyard-2* + 100 de Palmela).

Tabela 5.1: Resultados do Modelo 2 (validação) — SVY-2 + Palmela, 772 imagens

Escopo	P	R	F1	mAP@50
Todas as classes	54,3%	52,7%	53,5%	48,8%

Nota: O Roboflow Train, no plano gratuito, reporta apenas métricas globais no painel principal. Os valores por classe estão disponíveis nas ferramentas de avaliação avançada (plano pago).

Um mAP@50 de 48,8% é um resultado moderado mas coerente com as condições do Modelo 2: dataset de domínio misto (espanhol + português), quatro classes com densidades de instâncias muito distintas, e uma classe (*gomo*) completamente nova relativamente ao dataset base. A precisão (54,3%) e o recall (52,7%) equilibrados indicam que o modelo não está sistematicamente enviesado.

5.5 Resultados do Modelo 3 — Dataset Expandido

A Tabela 5.2 apresenta as métricas obtidas pelo Modelo 3, treinado sobre 938 imagens (geradas por augmentation a partir das imagens base disponíveis até 17 de junho de 2026).

Tabela 5.2: Resultados do Modelo 3 (validação) — 938 imagens

Escopo	P	R	F1	mAP@50
Todas as classes	57,3%	40,5%	47,4%	43,7%

A Figura 5.1 mostra uma inferência do Modelo 3 sobre uma imagem das vinhas de Palmela, com *confidence threshold* de 16%.




Figura 5.1: Inferência do Modelo 3 (threshold = 16%). Os sarmentos (ciano) são detetados com confiança até 91%; os gomos (roxo) surgem com confiança de 16–26%; um obstáculo/poste é detetado a vermelho com 71%.

5.6 Análise das Dificuldades Observadas

A análise das inferências do Modelo 3 permite identificar três padrões recorrentes de erro:

Gomos com confiança insuficiente: O modelo detecta a presença de gomos, mas a confiança atribuída (16–26%) fica abaixo do limiar convencional de 50%. Este

padrão indica que a classe está a ser aprendida, mas o volume de dados de treino é ainda insuficiente para calibrar adequadamente a confiança.

Sarmentos de fundo confundidos com sarmentos de frente: Em imagens com múltiplas videiras, sarmentos de segundo plano são por vezes detetados com alta confiança em detrimento dos de primeiro plano, pois têm maior contraste com o fundo.

Ausência de deteção de tronco em imagens de baixo contraste: Em imagens com terreno de cor similar ao tronco, este não é detetado, apesar de estar visível.

5.7 Comparação entre os Três Modelos

A Tabela 5.3 resume as diferenças fundamentais entre as três abordagens desenvolvidas neste estágio.

Tabela 5.3: Comparação entre os três modelos desenvolvidos

Aspeto	Modelo 1	Modelo 2	Modelo 3
Origem dos dados	<i>Segmentation-Vineyard-2</i>	SVY-2 + Pal-mela	SVY-2 + Pal-mela
Imagens base	≈ 300	≈ 400	$\approx 400+$
Imagens (aug.)	≈ 775	772	938
N.º de classes	3	4	4
Complexidade das imagens	Moderada	Alta	Alta
Aplicabilidade real	Limitada	Alta	Alta
mAP@50	—	48,8%	43,7%
Precisão	—	54,3%	57,3%
Recall	—	52,7%	40,5%
F1	—	53,5%	47,4%
Estado	Concluído	Concluído	Ativo

A transição do Modelo 2 para o Modelo 3 evidencia um padrão coerente com o aumento da dificuldade do dataset: o mAP@50 desce de 48,8% para 43,7%, mas a Precisão sobe de 54,3% para 57,3% (menos falsos positivos). A queda no Recall de 52,7% para 40,5% reflete principalmente a dificuldade de detetar gomos com confiança suficiente nas novas imagens de Palmela, mais complexas e variadas.

Capítulo 6

Conclusão e Trabalhos Futuros

6.1 Conclusão

O presente estágio teve como objetivo investigar a viabilidade de um sistema de **deteção automática de gomos em videiras** utilizando técnicas de visão computacional e *deep learning*, com vista à sua integração num futuro sistema robótico de poda mecanizada.

Ao longo do período de estágio foram desenvolvidos três modelos progressivos. O **Modelo 1**, baseado exclusivamente no dataset espanhol *Segmentation-Vineyard-2* (com anotações de *gomo* adicionadas), validou a *pipeline* técnica. O **Modelo 2**, construído sobre 400 imagens base (300 espanholas + 100 de Palmela, expandidas a 772 pelo *data augmentation* do Roboflow), obteve um mAP@50 de 48,8%, confirmando a viabilidade do sistema em domínio misto. O **Modelo 3**, com 938 imagens após augmentation, obteve um mAP@50 de 43,7% e Precisão de 57,3%, com os gomos a surgir em inferências a limiares de confiança de 16–26%, indicando que a classe está a ser aprendida e que o incremento do dataset resultará em melhoria contínua.

Os principais resultados e contribuições do estágio são:

- Construção de uma metodologia de aquisição e anotação de imagens adaptada à complexidade do ambiente vitícola português;
- Desenvolvimento de três versões progressivas de dataset, das 300 imagens base iniciais até 400+ imagens com quatro classes — *gomo*, *sarmento*, *tronco* e *objeto* — gerando 938 imagens para treino após augmentation do Roboflow;
- Identificação e documentação dos principais **desafios técnicos** associados à deteção de gomos em cenas reais: oclusões, fundo denso, variações de iluminação e alta densidade de instâncias;
- Avaliação da adequação do **YOLO26 Nano** para esta tarefa, com identificação dos seus pontos fortes (eficiência computacional, facilidade de integração) e limitações

(sensibilidade ao volume e qualidade dos dados de treino);

- Prova de conceito de que, com um dataset suficientemente grande e diverso, um modelo de detecção de objetos pode localizar gomos e sarmentos em imagens de campo com complexidade real.

É importante reconhecer que a obtenção de um modelo plenamente funcional e robusto para uso em sistemas robóticos reais **excede o âmbito de um único semestre de estágio**. A complexidade visual das imagens de Palmela, combinada com a necessidade de volumes de dados elevados, exige um esforço continuado. Contudo, as bases estabelecidas neste trabalho são um ponto de partida sólido e documentado para projetos de continuação.

6.2 Trabalhos Futuros

Com base na experiência adquirida e nas limitações identificadas, propõem-se as seguintes linhas de trabalho futuro:

6.2.1 Expansão e Diversificação do Dataset

- Aumentar o dataset de Palmela para um mínimo de **1000–2000 imagens anotadas**, cobrindo diferentes épocas do ano (pré-poda, pós-poda, início do abrolhamento) e diferentes condições meteorológicas.
- Incorporar imagens de outras regiões vitivinícolas portuguesas e de diferentes cultivares, para aumentar a diversidade do modelo.
- Explorar a **anotação semi-automática**: usar um modelo preliminar para gerar sugestões de anotação que sejam depois revistas manualmente, reduzindo o esforço por imagem.

6.2.2 Arquiteturas de Modelo Mais Avançadas

- Avaliar variantes maiores do YOLO26 (Small, Medium) ou modelos da geração seguinte (RT-DETR, YOLO-NAS) para determinar se o ganho em desempenho justifica o custo computacional adicional.
- Explorar a **segmentação de instâncias** (YOLO26-Seg) em vez de apenas *bounding boxes*, o que poderia fornecer informação mais precisa sobre a geometria dos sarmentos, útil para o cálculo do ponto de corte.

- Investigar modelos baseados em *transformers* para visão (DETR, Grounding DINO) que possam lidar melhor com oclusões severas.

6.2.3 Integração com Informação de Profundidade

A adição de uma câmera de profundidade (RGB-D) ao sistema permitiria:

- Separar objetos em primeiro e segundo plano com base na distância, reduzindo a confusão entre sarmentos de diferentes planos;
- Calcular as coordenadas 3D dos gomos para guiar o braço robótico ao ponto de corte preciso.

6.2.4 Validação em Ambiente Real

- Integrar o modelo desenvolvido num protótipo robótico e realizar testes *in situ* nas vinhas de Palmela;
- Definir métricas de desempenho operacional (taxa de gomos corretamente identificados por metro linear de vinha, tempo de processamento por frame).

6.2.5 Técnicas de *Data Augmentation* Específicas

- Explorar augmentações mais agressivas e específicas ao domínio, como simulação de diferentes condições de iluminação (*random brightness/contrast*), adição de ruído de movimento (*motion blur*) e recortes de imagens densas.
- Investigar técnicas de *mosaic augmentation* e *copy-paste* para aumentar artificialmente a densidade de instâncias por imagem.

Referências Bibliográficas

- [1] Arturo Aquino et al. «A new methodology for estimating the grapevine-berry number per cluster using image analysis». Em: *Biosystems Engineering* 156 (2017), pp. 80–95. DOI: [10.1016/j.biosystemseng.2017.01.009](https://doi.org/10.1016/j.biosystemseng.2017.01.009).
- [2] Tom Botterill et al. «A Robot System for Pruning Grape Vines». Em: *Journal of Field Robotics*. Vol. 34. 6. 2017, pp. 1100–1122. DOI: [10.1002/rob.21680](https://doi.org/10.1002/rob.21680).
- [3] Priyanto Hidayatullah e Refdinal Tubagus. «YOLO26: A Comprehensive Architecture Overview and Key Improvements». Em: *arXiv preprint arXiv:2602.14582* (2026). DOI: [10.48550/arXiv.2602.14582](https://doi.org/10.48550/arXiv.2602.14582). URL: <https://arxiv.org/abs/2602.14582>.
- [4] Glenn Jocher, Ayush Chaurasia e Jing Qiu. *Ultralytics YOLO*. <https://github.com/ultralytics/ultralytics>. Acedido em junho de 2026. 2023.
- [5] Anna Kicherer et al. «Automatic image-based analysis of field trials using the open-source tool BreedVision». Em: *Journal of Integrative Plant Biology* 57.1 (2015), pp. 110–119. DOI: [10.1111/jipb.12302](https://doi.org/10.1111/jipb.12302).
- [6] Yann LeCun, Yoshua Bengio e Geoffrey Hinton. «Deep learning». Em: *Nature* 521.7553 (2015), pp. 436–444. DOI: [10.1038/nature14539](https://doi.org/10.1038/nature14539).
- [7] Wei Liu et al. «SSD: Single Shot MultiBox Detector». Em: *European Conference on Computer Vision (ECCV)*. 2016, pp. 21–37. DOI: [10.1007/978-3-319-46448-0_2](https://doi.org/10.1007/978-3-319-46448-0_2).
- [8] Yaqoob Majeed et al. «Deep learning based segmentation for automated training of apple trees on trellis wires». Em: *Computers and Electronics in Agriculture* 170 (2020), p. 105231. DOI: [10.1016/j.compag.2020.105231](https://doi.org/10.1016/j.compag.2020.105231).
- [9] Sharada P. Mohanty, David P. Hughes e Marcel Salathé. «Using Deep Learning for Image-Based Plant Disease Detection». Em: *Frontiers in Plant Science* 7 (2016), p. 1419. DOI: [10.3389/fpls.2016.01419](https://doi.org/10.3389/fpls.2016.01419).
- [10] Stephen Nuske et al. «Yield Estimation in Vineyards by Visual Grape Detection». Em: *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. 2011, pp. 2352–2358. DOI: [10.1109/IROS.2011.6095143](https://doi.org/10.1109/IROS.2011.6095143).

- [11] Lucas Prado Osco et al. «A review of deep learning in unmanned aerial vehicles for agricultural applications». Em: *International Journal of Precision Agriculture* 22 (2021), pp. 1–24. DOI: [10.1007/s11119-021-09779-5](https://doi.org/10.1007/s11119-021-09779-5).
- [12] Joseph Redmon et al. «You Only Look Once: Unified, Real-Time Object Detection». Em: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016, pp. 779–788. DOI: [10.1109/CVPR.2016.91](https://doi.org/10.1109/CVPR.2016.91).
- [13] Shaoqing Ren et al. «Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks». Em: *Advances in Neural Information Processing Systems*. Vol. 28. 2015.
- [14] Roboflow Inc. *Roboflow*. <https://roboflow.com>. Acedido em junho de 2026. 2020.
- [15] Inkyu Sa et al. «DeepFruits: A Fruit Detection System Using Deep Neural Networks». Em: *Sensors*. Vol. 16. 8. 2016, p. 1222. DOI: [10.3390/s16081222](https://doi.org/10.3390/s16081222).
- [16] Tiago T. Santos et al. «Grape detection, segmentation, and tracking using deep neural networks and three-dimensional association». Em: *Computers and Electronics in Agriculture* 170 (2020), p. 105247. DOI: [10.1016/j.compag.2020.105247](https://doi.org/10.1016/j.compag.2020.105247).
- [17] Vinya. *Segmentation-Vineyard-2 Dataset*. <https://universe.roboflow.com/vinya/segmentation-vineyard-2>. Acedido em 13 de junho de 2026. Dez. de 2024.