

Detecção e Classificação Automática de Gomos em Videiras utilizando Visão Computacional e *Deep Learning*

Robson Alexander Alves¹, João Mendes¹, Inês Sena¹, Maurício Morais¹

¹Centro de Investigação em Digitalização e Robótica Inteligente (CEDRI), Instituto Politécnico de Bragança (IPB), Bragança, Portugal

a67712@alunos.ipb.pt

Resumo

A poda mecanizada da videira requer a identificação precisa dos gomos, estruturas de pequena dimensão que determinam os pontos de corte. Este artigo descreve o desenvolvimento de um sistema de detecção automática de gomos em videiras, baseado no modelo *YOLO26 Nano* e treinado sobre dois datasets distintos na plataforma Roboflow. Foram desenvolvidos três modelos incrementais: o primeiro utilizou o dataset público *Segmentation-Vineyard-2*, de origem espanhola, ao qual foram adicionadas manualmente anotações da classe *gomo* — ausente no dataset original. Os modelos seguintes combinam estas imagens com frames captados em vinhas da região de Palmela, Portugal, em condições próximas de um robô de poda real. Foram definidas quatro classes de anotação com propósitos robóticos específicos: *gomo* (pontos de corte), *sarmento* (guia estrutural), *tronco* (navegação) e *objeto* (obstáculos a evitar). O Modelo 1 (300 imagens, 3 classes) obteve mAP@50 de 48,8% e F1 de 53,5%. O Modelo 3, treinado sobre 938 imagens com quatro classes em condições de campo reais, obteve mAP@50 de 43,7%, Precisão de 57,3% e Recall de 40,5%, com os gomos a surgir nas inferências a limiares de confiança de 16%, indicando que a classe está a ser aprendida mas requer expansão do dataset.

Palavras-chave: visão computacional, *deep learning*, YOLO26, detecção de objetos, viticultura, gomos, poda mecanizada.

1. Introdução

A viticultura é uma das atividades agrícolas com maior relevância económica em Portugal e na Europa. A poda da videira, realizada tipicamente no inverno e início da primavera, é uma das operações culturais mais exigentes em mão de obra e requer operários experientes capazes de identificar os gomos produtivos e determinar os pontos de corte adequados.

A mecanização desta operação exige que sistemas robóticos percebam e interpretem a estrutura visual complexa de uma videira em ambiente real, incluindo sarmentos sobrepostos, variações de iluminação e fundos densos com múltiplos planos. A identificação automática de gomos constitui o pré-requisito fundamental para qualquer sistema de poda autónoma: sem essa capacidade, um robô não consegue determinar a posição de corte adequada acima de cada gomo.

Este trabalho foi desenvolvido no âmbito de um estágio curricular no *Centro de Investigação em Digitalização e Robótica Inteligente (CEDRI)* do *Instituto Politécnico de Bragança (IPB)*, entre março e julho de 2026. Os objetivos principais são: (i) recolher e anotar imagens de videiras em condições reais; (ii) treinar e avaliar modelos de deteção baseados em *deep learning* para identificação de gomos, sarmentos, troncos e obstáculos; (iii) estabelecer uma metodologia replicável de construção de dataset e treino de modelos.

2. Trabalhos Relacionados

2.1. Visão Computacional em Viticultura

A aplicação de visão computacional à viticultura tem vindo a crescer rapidamente. Santos *et al.* [8] e Nuske *et al.* [5] utilizaram redes neurais para estimativa do rendimento das vinhas por contagem de cachos, identificando as oclusões e a variabilidade de cor como desafios principais.

A identificação da estrutura esquelética da videira — tronco, cordões e sarmentos — foi explorada por Kicherer *et al.* [3] e Majeed *et al.* [4], demonstrando que a segmentação dos elementos estruturais melhora a robustez da localização dos pontos de corte. Botterill *et al.* [1] desenvolveram um sistema robótico de poda que inclui deteção de gomos com câmeras RGB e de profundidade.

2.2. Modelos de Deteção de Objetos

Os modelos da família YOLO (*You Only Look Once*) [6] tornaram-se referência para deteção em tempo real, combinando velocidade e precisão numa única passagem pela rede. O YOLO26 [2], a versão mais recente, introduz inferência *End-to-End NMS-free* (sem *Non-Maximum Suppression*), o otimizador MuSGD e o *Small-Target-Aware Label Assignment* (STAL), obtendo um ganho de 43% na velocidade em modo CPU face ao YOLOv8, o que o torna adequado para sistemas robóticos de campo.

A plataforma Roboflow [7] tem emergido como ferramenta de referência para anotação, gestão de versões e treino de modelos em domínios agrícolas, combinando interface de anotação manual com funcionalidades de *data augmentation* e treino na nuvem.

3. Metodologia

3.1. Estratégia Geral

O sistema segue uma *pipeline* de visão computacional supervisionada: aquisição de vídeo em campo, extração e anotação de frames, treino do modelo YOLO26 Nano e avaliação das métricas de desempenho. Foram desenvolvidos três modelos com datasets de complexidade crescente.

Nota sobre *Data Augmentation*. Os counts de imagens reportados no painel do Roboflow incluem imagens geradas automaticamente por *data augmentation* (rotações, espelhos, variações de brilho e contraste). As contagens de imagens *base* referem-se às imagens originalmente anotadas; os valores após *augmentation* são os efetivamente utilizados no treino.

3.2. Imagens Base

Fonte 1 — *Segmentation-Vineyard-2*. O conjunto de partida é o dataset público *Segmentation-Vineyard-2* [9], de origem espanhola, disponível no Roboflow Universe. O dataset original continha anotações de *sarmento* e *tronco*. A contribuição deste trabalho consistiu em anotar manualmente os *gomos* em todas as 300 imagens, completando as três classes: *gomo*, *sarmento* e *tronco*.

Fonte 2 — *Vinhas de Palmela*. Vídeos captados em vinhas da região de Palmela em março de 2026, com câmera de *smartphone* a uma taxa de 2 fps, simulando o trajeto de um robô de poda. Os vídeos foram importados no Roboflow, que realizou a extração automática dos *frames*. Até à data, foram anotadas aproximadamente 100 imagens com as quatro classes completas (*gomo*, *sarmento*, *tronco*, *objeto*).

Todos os datasets foram divididos nas proporções **70% treino / 20% validação / 10% teste**. A Tabela 1 resume a composição de cada versão do dataset.

Tabela 1: Composição dos datasets por modelo

Modelo	Base SVY-2	Base Palmela	Base total	Após augmentation
Modelo 1	300	0	300	≈ 775
Modelo 2	300	100	400	772
Modelo 3	300	100+	400+	938

3.3. Classes de Anotação

Foram definidas quatro classes, cada uma com um propósito específico na operação robótica (Tabela 2). As anotações foram realizadas manualmente na interface do Roboflow, com a política de marcar o máximo de gomos identificáveis: os locais de inserção dos gomos nos sarmentos são reconhecíveis mesmo a distância, pelo que a omissão introduziria falsos negativos sistemáticos no treino.

Tabela 2: Classes de anotação e propósito robótico


Classe	Propósito robótico	Critério de anotação
<i>gomo</i>	Pontos de corte para poda	Todos os gomos identificáveis; posição nos sarmentos é reconhecível mesmo a distância
<i>sarmento</i>	Guia estrutural para gomos	Anotado se $\geq 30\%$ visível
<i>tronco</i>	Navegação entre videiras	Sempre que visível no frame
<i>objeto</i>	Obstáculos a evitar (estacas, mangueiras)	Elementos não classificáveis nas outras classes

As principais dificuldades encontradas na anotação foram: (i) *lentidão da plataforma* quando uma imagem acumula mais de 300 *bounding boxes*, situação comum nas imagens de Palmela; (ii) *ausência de seleção automática para sarmentos* — a ferramenta *Auto-label* do Roboflow mostrou-se ineficaz em estruturas finas e sobrepostas, exigindo anotação inteiramente manual.

A Figura 1 ilustra uma imagem das vinhas de Palmela antes e após anotação, e a distribuição de instâncias por classe.



(a) Imagem original



(b) Com anotações (>300 *bounding boxes*)

Annotations

329

Group: objects

Classes

Layers

● gomo

161

● objects

19

● sarmiento

141

● tronco

8

3.4. Arquitetura do Modelo — YOLO26 Nano

O modelo selecionado foi o *YOLO26 Nano* [2], desenvolvido pela Ultralytics e lançado em janeiro de 2026 com o lema "*Built End-to-End. Built for the Edge*". As principais inovações relevantes para este trabalho são:

- *End-to-End NMS-free inference*: eliminação da etapa de pós-processamento NMS (*Non-Maximum Suppression*), com ganho de 43% na velocidade em modo CPU;
- *STAL* (*Small-Target-Aware Label Assignment*): garante um mínimo de quatro âncoras para objetos com dimensão inferior a 8×8 px — crucial para gomos de pequena dimensão;
- *PSABlock* no *neck*: mecanismo de atenção global que melhora a representação de características sem custo computacional elevado;
- *MuSGD*: otimizador híbrido SGD/Muon que melhora a convergência em datasets de dimensão reduzida.

A Figura 2 apresenta o diagrama de arquitetura do YOLO26.

YOLO26




Figura 2: Arquitetura do YOLO26 Nano: Backbone (C3k2 + SPPF com atalho residual), Neck (C2PSA com PSABlock) e três cabeças de detecção. Fonte: [2].

3.5. Procedimento de Treino

O treino foi realizado na plataforma *Roboflow Train* (nuvem), dispensando infraestrutura local com GPU. A Tabela 3 resume a configuração utilizada em ambos os modelos.

Tabela 3: Configuração de treino (ambos os modelos)

Parâmetro	Valor
Plataforma	Roboflow Train (nuvem)
Modelo base	YOLO26 Nano (pesos COCO)
Épocas	100
Tamanho de imagem	640×640 px
Divisão treino/val/teste	70% / 20% / 10%

4. Resultados e Discussão

4.1. Modelo 1 — *Segmentation-Vineyard-2* (300 imagens base)

O Modelo 1 foi treinado exclusivamente sobre as 300 imagens do *Segmentation-Vineyard-2*, com as anotações de *gomo* adicionadas manualmente, perfazendo três classes. O Roboflow expandiu este conjunto para aproximadamente 775 imagens através de *data augmentation*. Este modelo serviu para validar a *pipeline* técnica com um dataset de domínio único (vinhas espanholas), antes da introdução de imagens de Palmela. Os sarmentos foram detetados com elevada confiança (até 97%) e os troncos com confiança acima de 83%, confirmando que o YOLO26 Nano aprende a estrutura visual das videiras mesmo com datasets pequenos.

4.2. Modelo 2 — SVY-2 + Palmela (400 imagens base, 772 aumentadas)

O Modelo 2 incorpora as 100 imagens de Palmela ao dataset do Modelo 1, perfazendo 400 imagens base com quatro classes; o Roboflow gerou 772 imagens para treino através de *augmentation*. A Tabela 4 apresenta as métricas obtidas no conjunto de validação.

Tabela 4: Métricas do Modelo 2 — conjunto de validação

Métrica	Valor
mAP@50	48,8%
Precisão	54,3%
Recall	52,7%
F1	53,5%

Um mAP@50 de 48,8% é um resultado moderado mas coerente com as características do problema: domínio misto (espanhol + português), quatro classes com densidades de instâncias muito distintas e uma classe (*gomo*) completamente nova relativamente ao dataset original. A precisão (54,3%) e o recall (52,7%) equilibrados indicam que o modelo

distribui as dificuldades de forma homogênea entre falsos positivos e falsos negativos, sem enviesamento sistemático para nenhuma classe.

4.3. Modelo 3 — Dataset Expandido (400+ imagens base, 938 aumentadas)

O Modelo 3 representa o estado mais avançado do desenvolvimento, treinado sobre 938 imagens (geradas por augmentation a partir das imagens base disponíveis até 17 de junho de 2026). A Tabela 5 apresenta as métricas obtidas no conjunto de validação.

Tabela 5: Métricas do Modelo 3 (V3) — conjunto de validação

Métrica	Valor
mAP@50	43,7%
Precisão	57,3%
Recall	40,5%
F1	47,4%

A Figura 3 mostra uma inferência do Modelo 3 sobre uma imagem das vinhas de Palmela, com *confidence threshold* de 16%.




Figura 3: Inferência do Modelo 3 sobre imagem das vinhas de Palmela (*threshold* = 16%). Sarmentos (ciano), gomos (roxo), objetos (vermelho). Os gomos surgem com confiança baixa (16–26%), enquanto os sarmentos atingem confiança até 91%.

A inferência revela um comportamento que reflete a assimetria de dificuldade entre classes: os sarmentos são detetados com elevada confiança (até 91%), pois são estruturas

visualmente distintas e de grande dimensão; os gomos, em contraste, apenas surgem com *threshold* abaixo de 16%, o que indica que o modelo ainda está a calibrar a confiança nesta classe mais difícil. Este resultado é esperado — os gomos têm dimensão reduzida, apresentam variabilidade de forma e aparecem com frequências muito distintas entre imagens, tornando a aprendizagem mais lenta.

4.4. Discussão Comparativa

A Tabela 6 compara as três abordagens desenvolvidas.

Tabela 6: Comparação entre os modelos desenvolvidos

Aspeto	Modelo 1	Modelo 2	Modelo 3
Fontes	SVY-2	SVY-2 + Palmela	SVY-2 + Palmela
Imagens base	≈ 300	≈ 400	$\approx 400+$
Imagens (aug.)	≈ 775	772	938
Classes	3	4	4
mAP@50	—	48,8%	43,7%
Precisão	—	54,3%	57,3%
Recall	—	52,7%	40,5%
F1	—	53,5%	47,4%

A transição do Modelo 2 para o Modelo 3 evidencia um padrão esperado face à maior dificuldade do dataset expandido: o mAP@50 desce de 48,8% para 43,7%, mas a Precisão sobe de 54,3% para 57,3%, indicando menos falsos positivos. A queda no Recall (de 52,7% para 40,5%) reflete a dificuldade de detetar gomos em imagens de Palmela com maior complexidade visual — o modelo detecta-os, mas a confiança não atinge o limiar convencional de 50%. A adição contínua de imagens de Palmela é o principal vetor de melhoria, prevendo-se que alcançar 2000–3000 imagens base resulte num salto significativo no Recall dos gomos.

5. Conclusão

Este artigo apresentou o desenvolvimento iterativo de um sistema de deteção automática de gomos em videiras baseado no YOLO26 Nano, com aplicação a sistemas robóticos de poda mecanizada. Foram desenvolvidos três modelos progressivos, desde 300 a 938 imagens, evidenciando uma metodologia replicável de construção de dataset e treino incremental.

O trabalho demonstrou que: (i) é possível adaptar um dataset público de sarmentos e troncos para incluir a deteção de gomos através de anotação manual; (ii) o YOLO26 Nano aprende a estrutura visual de videiras com datasets de dimensão reduzida, atingindo

mAP@50 de 48,8% no Modelo 2 e 43,7% no Modelo 3 (domínio mais difícil, 4 classes); (iii) a plataforma Roboflow Train viabiliza o treino de modelos de qualidade sem infraestrutura local de GPU; (iv) a deteção de gomos em cenas reais é um problema exigente — os gomos surgem com confiança reduzida mesmo no Modelo 3, o que indica que o volume de dados é ainda insuficiente para calibrar esta classe.

As principais direções de trabalho futuro são: expansão do dataset de Palmela para 2000–3000 imagens anotadas; avaliação de variantes maiores do YOLO26 (Small, Medium) à medida que o dataset crescer; integração com câmeras de profundidade para estimativa 3D dos pontos de corte; e exploração de YOLO26-Seg para segmentação de instâncias de sarmentos.

Agradecimentos

O autor agradece ao Instituto Politécnico de Bragança (IPB) e ao Centro de Investigação em Digitalização e Robótica Inteligente (CEDRI) pela infraestrutura e apoio disponibilizados, e a todos os colegas e investigadores que contribuíram com sugestões e discussões ao longo deste trabalho.

Referências

- [1] Tom Botterill et al. «A Robot System for Pruning Grape Vines». Em: *Journal of Field Robotics*. Vol. 34. 6. 2017, pp. 1100–1122. DOI: [10.1002/rob.21680](https://doi.org/10.1002/rob.21680).
- [2] Priyanto Hidayatullah e Refdinal Tubagus. «YOLO26: A Comprehensive Architecture Overview and Key Improvements». Em: *arXiv preprint arXiv:2602.14582* (2026). DOI: [10.48550/arXiv.2602.14582](https://doi.org/10.48550/arXiv.2602.14582). URL: <https://arxiv.org/abs/2602.14582>.
- [3] Anna Kicherer et al. «Automatic image-based analysis of field trials using the open-source tool BreedVision». Em: *Journal of Integrative Plant Biology* 57.1 (2015), pp. 110–119. DOI: [10.1111/jipb.12302](https://doi.org/10.1111/jipb.12302).
- [4] Yaqoob Majeed et al. «Deep learning based segmentation for automated training of apple trees on trellis wires». Em: *Computers and Electronics in Agriculture* 170 (2020), p. 105231. DOI: [10.1016/j.compag.2020.105231](https://doi.org/10.1016/j.compag.2020.105231).
- [5] Stephen Nuske et al. «Yield Estimation in Vineyards by Visual Grape Detection». Em: *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. 2011, pp. 2352–2358. DOI: [10.1109/IROS.2011.6095143](https://doi.org/10.1109/IROS.2011.6095143).
- [6] Joseph Redmon et al. «You Only Look Once: Unified, Real-Time Object Detection». Em: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016, pp. 779–788. DOI: [10.1109/CVPR.2016.91](https://doi.org/10.1109/CVPR.2016.91).
- [7] Roboflow Inc. *Roboflow*. <https://roboflow.com>. Acedido em junho de 2026. 2020.

- [8] Tiago T. Santos et al. «Grape detection, segmentation, and tracking using deep neural networks and three-dimensional association». Em: *Computers and Electronics in Agriculture* 170 (2020), p. 105247. DOI: [10.1016/j.compag.2020.105247](https://doi.org/10.1016/j.compag.2020.105247).
- [9] Vinya. *Segmentation-Vineyard-2 Dataset*. <https://universe.roboflow.com/vinya/segmentation-vineyard-2>. Acedido em 13 de junho de 2026. Dez. de 2024.