

Deteção e Classificação Automática de Gomos em Videiras utilizando Visão Computacional e *Deep Learning*

Robson Alexander Alves¹, João Mendes¹, Inês Sena¹, Maurício Morais¹

¹Centro de Investigação em Digitalização e Robótica Inteligente (CEDRI), Instituto Politécnico de Bragança (IPB), Bragança, Portugal
a67712@alunos.ipb.pt

Resumo

A poda mecanizada da videira requer a identificação precisa dos gomos, estruturas de pequena dimensão que determinam os pontos de corte. Este artigo descreve o desenvolvimento de um sistema de deteção automática de gomos em videiras, baseado no modelo *YOLO26 Nano* e treinado sobre dois **datasets** distintos na plataforma **Roboflow**. Foram desenvolvidos três modelos incrementais: o primeiro utilizou o dataset público *Segmentation-Vineyard-2*, de origem espanhola, ao qual foram adicionadas manualmente anotações da classe *gomo* — ausente no **dataset** original. Os modelos seguintes combinam estas imagens com **frames** captados em vinhas da região de Palmela, Portugal, em condições próximas de um robô de poda real. Foram definidas quatro classes de anotação com propósitos robóticos específicos: *gomo* (pontos de corte), *sarmento* (guia estrutural), *tronco* (navegação) e *objeto* (obstáculos a evitar). O **Modelo 1** (300 imagens, 3 classes) obteve mAP@50 de 48,8% e F1 de 53,5%. O **Modelo 3**, treinado sobre 938 imagens com quatro classes em condições de campo reais, obteve mAP@50 de 43,7%, Precisão de 57,3% e Recall de 40,5%, com os gomos a surgir nas inferências a limiares de confiança de 16%, indicando que a classe está a ser aprendida mas requer expansão do dataset.

Palavras-chave: visão computacional, *deep learning*, YOLO26, deteção de objetos, viticultura, gomos, poda mecanizada.

1. Introdução

A viticultura é uma das atividades agrícolas com maior relevância económica em Portugal e na Europa. A poda da videira, realizada tipicamente no inverno e início da primavera, é uma das operações culturais mais exigentes em mão de obra e requer operários experientes capazes de identificar os gomos produtivos e determinar os pontos de corte adequados.

A mecanização desta operação exige que sistemas robóticos percebam e interpretem a estrutura visual complexa de uma videira em ambiente real, incluindo sarmentos sobrepostos, variações de iluminação e fundos densos com múltiplos planos. A identificação automática de gomos constitui o pré-requisito fundamental para qualquer sistema de poda autónoma: sem essa capacidade, um robô não consegue determinar a posição de corte adequada acima de cada gomo.

Este trabalho foi desenvolvido no âmbito de um estágio curricular no *Centro de Investigação em Digitalização e Robótica Inteligente (CEDRI)* do *Instituto Politécnico de Bragança (IPB)*, entre março e julho de 2026. Os objetivos principais são: (i) recolher e anotar imagens de videiras em condições reais; (ii) treinar e avaliar modelos de deteção baseados em *deep learning* para identificação de gomos, sarmentos, troncos e obstáculos; (iii) estabelecer uma metodologia replicável de construção de dataset e treino de modelos.

2. Trabalhos Relacionados

2.1. Visão Computacional em Viticultura

A aplicação de visão computacional à viticultura tem vindo a crescer rapidamente. Santos *et al.* [8] e Nuske *et al.* [5] utilizaram redes neurais para estimativa do rendimento das vinhas por contagem de cachos, identificando as oclusões e a variabilidade de cor como desafios principais.

A identificação da estrutura esquelética da videira — tronco, cordões e sarmentos — foi explorada por Kicherer *et al.* [3] e Majeed *et al.* [4], demonstrando que a segmentação dos elementos estruturais melhora a robustez da localização dos pontos de corte. Botterill *et al.* [1] desenvolveram um sistema robótico de poda que inclui deteção de gomos com câmeras RGB e de profundidade.

2.2. Modelos de Deteção de Objetos

Os modelos da família YOLO (*You Only Look Once*) [6] tornaram-se referência para deteção em tempo real, combinando velocidade e precisão numa única passagem pela rede. O YOLO26 [2], a versão mais recente, introduz inferência *End-to-End NMS-free* (sem *Non-Maximum Suppression*), o otimizador MuSGD e o *Small-Target-Aware Label Assignment* (STAL), obtendo um ganho de 43% na velocidade em modo CPU face ao YOLOv8, o que o torna adequado para sistemas robóticos de campo.

A plataforma Roboflow [7] tem emergido como ferramenta de referência para anotação, gestão de versões e treino de modelos em domínios agrícolas, combinando interface de anotação manual com funcionalidades de *data augmentation* e treino na nuvem.

3. Metodologia

3.1. Estratégia Geral

O sistema segue uma *pipeline* de visão computacional supervisionada: aquisição de vídeo em campo, extração e anotação de frames, treino do modelo YOLO26 Nano e avaliação das métricas de desempenho. Foram desenvolvidos três modelos com datasets de complexidade crescente.

Nota sobre *Data Augmentation*. Os counts de imagens reportados no painel do Roboflow incluem imagens geradas automaticamente por *data augmentation* (rotações, espelhos, variações de brilho e contraste). As contagens de imagens *base* referem-se às imagens originalmente anotadas; os valores após *augmentation* são os efetivamente utilizados no treino.

3.2. Imagens Base

Fonte 1 — *Segmentation-Vineyard-2*. O conjunto de partida é o dataset público *Segmentation-Vineyard-2* [9], de origem espanhola, disponível no Roboflow Universe. O dataset original continha anotações de *sarmento* e *tronco*. A contribuição deste trabalho consistiu em anotar manualmente os *gomos* em todas as 300 imagens, completando as três classes: *gomo*, *sarmento* e *tronco*.

Fonte 2 — *Vinhas de Palmela*. Vídeos captados em vinhas da região de Palmela em março de 2026, com câmera de *smartphone* a uma taxa de 2 fps, simulando o trajeto de um robô de poda. Os vídeos foram importados no Roboflow, que realizou a extração automática dos *frames*. Até à data, foram anotadas aproximadamente 100 imagens com as quatro classes completas (*gomo*, *sarmento*, *tronco*, *objeto*).

Todos os datasets foram divididos nas proporções **70% treino / 20% validação / 10% teste**. A Tabela 1 resume a composição de cada versão do dataset.

Tabela 1: Composição dos datasets por modelo

Modelo	Base SVY-2	Base Palmela	Base total	Após augmentation
Modelo 1	300	0	300	≈775
Modelo 2	300	100	400	772
Modelo 3	300	100+	400+	938

3.3. Classes de Anotação

Foram definidas quatro classes, cada uma com um propósito específico na operação robótica (Tabela 2). As anotações foram realizadas manualmente na interface do Roboflow, com a política de marcar o máximo de gomos identificáveis: os locais de inserção dos gomos nos sarmentos são reconhecíveis mesmo a distância, pelo que a omissão introduziria falsos negativos sistemáticos no treino.

Tabela 2: Classes de anotação e propósito robótico


Classe	Propósito robótico	Critério de anotação
<i>gomo</i>	Pontos de corte para poda	Todos os gomos identificáveis; posição nos sarmentos é reconhecível mesmo a distância
<i>sarmento</i>	Guia estrutural para gomos	Anotado se $\geq 30\%$ visível
<i>tronco</i>	Navegação entre videiras	Sempre que visível no frame
<i>objeto</i>	Obstáculos a evitar (estacas, mangueiras)	Elementos não classificáveis nas outras classes

As principais dificuldades encontradas na anotação foram: (i) *lentidão da plataforma* quando uma imagem acumula mais de 300 *bounding boxes*, situação comum nas imagens de Palmela; (ii) *ausência de seleção automática para sarmentos* — a ferramenta *Auto-label* do Roboflow mostrou-se ineficaz em estruturas finas e sobrepostas, exigindo anotação inteiramente manual.

A Figura 1 ilustra uma imagem das vinhas de Palmela antes e após anotação, e a distribuição de instâncias por classe.



(a) Imagem original



(b) Com anotações (>300 *bounding boxes*)

Annotations

329

Group: objects

Classes

Layers

● gomo

161

● objects

19

● sarmiento

141

● tronco

8

3.4. Arquitetura do Modelo — YOLO26 Nano

O modelo selecionado foi o *YOLO26 Nano* [2], desenvolvido pela Ultralytics e lançado em janeiro de 2026 com o lema "*Built End-to-End. Built for the Edge*". As principais inovações relevantes para este trabalho são:

- *End-to-End NMS-free inference*: eliminação da etapa de pós-processamento NMS (*Non-Maximum Suppression*), com ganho de 43% na velocidade em modo CPU;
- *STAL* (*Small-Target-Aware Label Assignment*): garante um mínimo de quatro âncoras para objetos com dimensão inferior a 8×8 px — crucial para gomos de pequena dimensão;
- *PSABlock* no *neck*: mecanismo de atenção global que melhora a representação de características sem custo computacional elevado;
- *MuSGD*: otimizador híbrido SGD/Muon que melhora a convergência em datasets de dimensão reduzida.

A Figura 2 apresenta o diagrama de arquitetura do YOLO26.

YOLO26




Figura 2: Arquitetura do YOLO26 Nano: Backbone (C3k2 + SPPF com atalho residual), Neck (C2PSA com PSABlock) e três cabeças de detecção. Fonte: [2].

3.5. Procedimento de Treino

O treino foi realizado na plataforma *Roboflow Train* (nuvem), dispensando infraestrutura local com GPU. A Tabela 3 resume a configuração utilizada em ambos os modelos.

Tabela 3: Configuração de treino (ambos os modelos)

Parâmetro	Valor
Plataforma	Roboflow Train (nuvem)
Modelo base	YOLO26 Nano (pesos COCO)
Épocas	100
Tamanho de imagem	640×640 px
Divisão treino/val/teste	70% / 20% / 10%

4. Resultados e Discussão

4.1. Modelo 1 — *Segmentation-Vineyard-2* (300 imagens base)

O Modelo 1 foi treinado exclusivamente sobre as 300 imagens do *Segmentation-Vineyard-2*, com as anotações de *gomo* adicionadas manualmente, perfazendo três classes. O Roboflow expandiu este conjunto para aproximadamente 775 imagens através de *data augmentation*. Este modelo serviu para validar a *pipeline* técnica com um dataset de domínio único (vinhas espanholas), antes da introdução de imagens de Palmela. Os sarmentos foram detetados com elevada confiança (até 97%) e os troncos com confiança acima de 83%, confirmando que o YOLO26 Nano aprende a estrutura visual das videiras mesmo com datasets pequenos.

4.2. Modelo 2 — SVY-2 + Palmela (400 imagens base, 772 aumentadas)

O Modelo 2 incorpora as 100 imagens de Palmela ao dataset do Modelo 1, perfazendo 400 imagens base com quatro classes; o Roboflow gerou 772 imagens para treino através de *augmentation*. A Tabela 4 apresenta as métricas obtidas no conjunto de validação.

Tabela 4: Métricas do Modelo 2 — conjunto de validação

Métrica	Valor
mAP@50	48,8%
Precisão	54,3%
Recall	52,7%
F1	53,5%

Um mAP@50 de 48,8% é um resultado moderado mas coerente com as características do problema: domínio misto (espanhol + português), quatro classes com densidades de instâncias muito distintas e uma classe (*gomo*) completamente nova relativamente ao dataset original. A precisão (54,3%) e o recall (52,7%) equilibrados indicam que o modelo

distribui as dificuldades de forma homogênea entre falsos positivos e falsos negativos, sem enviesamento sistemático para nenhuma classe.

4.3. Modelo 3 — Dataset Expandido (400+ imagens base, 938 aumentadas)

O Modelo 3 representa o estado mais avançado do desenvolvimento, treinado sobre 938 imagens (geradas por **augmentation** a partir das imagens base disponíveis até 17 de junho de 2026). A Tabela 5 apresenta as métricas obtidas no conjunto de validação.

Tabela 5: Métricas do Modelo 3 (V3) — conjunto de validação

Métrica	Valor
mAP@50	43,7%
Precisão	57,3%
Recall	40,5%
F1	47,4%

A Figura 3 mostra uma inferência do Modelo 3 sobre uma imagem das vinhas de Palmela, com *confidence threshold* de 16%.




Figura 3: Inferência do Modelo 3 sobre imagem das vinhas de Palmela (*threshold* = 16%). Sarmentos (ciano), gomos (roxo), objetos (vermelho). Os **gomos** surgem com confiança baixa (16–26%), enquanto os sarmentos atingem confiança até 91%.

A inferência revela um comportamento que reflete a assimetria de dificuldade entre classes: os sarmentos são detetados com elevada confiança (até 91%), pois são estruturas

visualmente distintas e de grande dimensão; os **gomos**, em contraste, apenas surgem com *threshold* abaixo de 16%, o que indica que o modelo ainda está a calibrar a confiança nesta classe mais difícil. Este resultado é esperado — os **gomos** têm dimensão reduzida, apresentam variabilidade de forma e aparecem com frequências muito distintas entre imagens, tornando a aprendizagem mais lenta.

4.4. Discussão Comparativa

A Tabela 6 compara as três abordagens desenvolvidas.

Tabela 6: Comparação entre os modelos desenvolvidos

Aspeto	Modelo 1	Modelo 2	Modelo 3
Fontes	SVY-2	SVY-2 + Palmela	SVY-2 + Palmela
Imagens base	≈ 300	≈ 400	$\approx 400+$
Imagens (aug.)	≈ 775	772	938
Classes	3	4	4
mAP@50	—	48,8%	43,7%
Precisão	—	54,3%	57,3%
Recall	—	52,7%	40,5%
F1	—	53,5%	47,4%

A transição do Modelo 2 para o Modelo 3 evidencia um padrão esperado face à maior dificuldade do **dataset** expandido: o mAP@50 desce de 48,8% para 43,7%, mas a Precisão sobe de 54,3% para 57,3%, indicando menos falsos positivos. A queda no **Recall** (de 52,7% para 40,5%) reflete a dificuldade de detetar gomos em imagens de Palmela com maior complexidade visual — o modelo detecta-os, mas a confiança não atinge o limiar convencional de 50%. A adição contínua de imagens de Palmela é o principal vetor de melhoria, prevendo-se que alcançar 2000–3000 imagens base resulte num salto significativo no **Recall** dos gomos.

5. Conclusão

Este artigo apresentou o desenvolvimento iterativo de um sistema de deteção automática de gomos em videiras baseado no **YOLO26 Nano**, com aplicação a sistemas robóticos de poda mecanizada. Foram desenvolvidos três modelos progressivos, desde 300 a 938 imagens, evidenciando uma metodologia replicável de construção de **dataset** e treino incremental.

O trabalho demonstrou que: (i) é possível adaptar um **dataset** público de sarmentos e troncos para incluir a deteção de gomos através de anotação manual; (ii) o **YOLO26 Nano** aprende a estrutura visual de videiras com **datasets** de dimensão reduzida, atingindo

mAP@50 de 48,8% no Modelo 2 e 43,7% no Modelo 3 (domínio mais difícil, 4 classes); (iii) a plataforma Roboflow Train viabiliza o treino de modelos de qualidade sem infraestrutura local de GPU; (iv) a deteção de gomos em cenas reais é um problema exigente — os gomos surgem com confiança reduzida mesmo no Modelo 3, o que indica que o volume de dados é ainda insuficiente para calibrar esta classe.

As principais direções de trabalho futuro são: expansão do dataset de Palmela para 2000–3000 imagens anotadas; avaliação de variantes maiores do YOLO26 (Small, Medium) à medida que o dataset crescer; integração com câmeras de profundidade para estimativa 3D dos pontos de corte; e exploração de YOLO26-Seg para segmentação de instâncias de sarmentos.

Agradecimentos

O autor agradece ao Instituto Politécnico de Bragança (IPB) e ao Centro de Investigação em Digitalização e Robótica Inteligente (CEDRI) pela infraestrutura e apoio disponibilizados, e a todos os colegas e investigadores que contribuíram com sugestões e discussões ao longo deste trabalho.

Referências

- [1] Tom Botterill et al. «A Robot System for Pruning Grape Vines». Em: *Journal of Field Robotics*. Vol. 34. 6. 2017, pp. 1100–1122. DOI: [10.1002/rob.21680](https://doi.org/10.1002/rob.21680).
- [2] Priyanto Hidayatullah e Refdinal Tubagus. «YOLO26: A Comprehensive Architecture Overview and Key Improvements». Em: *arXiv preprint arXiv:2602.14582* (2026). DOI: [10.48550/arXiv.2602.14582](https://doi.org/10.48550/arXiv.2602.14582). URL: <https://arxiv.org/abs/2602.14582>.
- [3] Anna Kicherer et al. «Automatic image-based analysis of field trials using the open-source tool BreedVision». Em: *Journal of Integrative Plant Biology* 57.1 (2015), pp. 110–119. DOI: [10.1111/jipb.12302](https://doi.org/10.1111/jipb.12302).
- [4] Yaqoob Majeed et al. «Deep learning based segmentation for automated training of apple trees on trellis wires». Em: *Computers and Electronics in Agriculture* 170 (2020), p. 105231. DOI: [10.1016/j.compag.2020.105231](https://doi.org/10.1016/j.compag.2020.105231).
- [5] Stephen Nuske et al. «Yield Estimation in Vineyards by Visual Grape Detection». Em: *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. 2011, pp. 2352–2358. DOI: [10.1109/IROS.2011.6095143](https://doi.org/10.1109/IROS.2011.6095143).
- [6] Joseph Redmon et al. «You Only Look Once: Unified, Real-Time Object Detection». Em: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016, pp. 779–788. DOI: [10.1109/CVPR.2016.91](https://doi.org/10.1109/CVPR.2016.91).
- [7] Roboflow Inc. *Roboflow*. <https://roboflow.com>. Acedido em junho de 2026. 2020.

- [8] Tiago T. Santos et al. «Grape detection, segmentation, and tracking using deep neural networks and three-dimensional association». Em: *Computers and Electronics in Agriculture* 170 (2020), p. 105247. DOI: [10.1016/j.compag.2020.105247](https://doi.org/10.1016/j.compag.2020.105247).
- [9] Vinya. *Segmentation-Vineyard-2 Dataset*. <https://universe.roboflow.com/vinya/segmentation-vineyard-2>. Acedido em 13 de junho de 2026. Dez. de 2024.